Projet GM3 : Classificationn Hiérarchique

Ensemble de données agricoles avancées sur le soja (2025)

GNAMAH Tchamie Boris (*boris.gnamah$_t$chamie@insa−rouen.fr*)

Envoyez moi un mail à cette adresse pour recevoir le dataset.

L'≪ Advanced Soybean Agricultural Dataset ≫ est un ensemble de données méticuleusement organisé conçu pour soutenir la recherche agricole et les applications d'apprentissage automatique. Cet ensemble de données se compose de 55 450 lignes et 13 colonnes, capturant les paramètres agricoles essentiels liés aux plants de soja. L'ensemble de données comprend diverses caractéristiques telles que la hauteur de la plante, le nombre de gousses, le poids biologique, la teneur en chlorophylle, le pourcentage de protéines, le rendement en graines et la teneur relative en eau des feuilles. Ces attributs sont cruciaux pour comprendre la croissance, la productivité et la valeur nutritionnelle des cultures de soja dans différentes conditions environnementales.

On veut trouver des classes de paramètre qui se ressemblent sur 6 variables pertinentes de votre choix. À partir de l'Advanced Soybean Agricultural Dataset,

1. Faire un clustering par CAH de Ward sur les données brutes,puis sur les données standardisées.
2. Visualiser le clustering des données brutes sur le plan défini par les deux premiers axes d'une ACP non normée. Interpréter la partition en 5 classes obtenues sur les données brutes.Qu'en pensez-vous ?
3. Visualiser le clustering des données standardisées sur le plan défini par

les deux premiers axes d'une ACP normée. Interpréter la partition en 5 classes obtenues sur les données standardisées.Qu'en pensez-vous ?

4. Suite aux résultats précédents, est il important de standardiser les données avant de faire un clustering ?

— **Données standardisées :** Variables centrées réduites
— **ACP normée :** c'est une ACP dont les variables sont centrées réduites

Language utilisé : Python ou R