Projet GM3 : Classificationn Hiérarchique

Clustering des données standardisées et non standardisées

GNAMAH Tchamie Boris (*boris.gnamah$_t$chamie@insa−rouen.fr*)

Envoyez moi un mail à cette adresse pour recevoir le dataset.

On utilise les données USArrests où 50 états Amériains sont décrit par :

- 3 variables indiquant le nombre(pour 100000h abitants)d'arrestation pour meurtre(Murder),agressions (Assault),viol (Rape),
- Une variable indiquant la proportion de population urbaine(UrbanPop).

On veut trouver des classes d'états qui se ressemblent sur les 3 variables de crimes. À partir des données USArrests.csv,

1. Faire un clustering par CAH de Ward sur les données brutes,puis sur les données standardisées.
2. Visualiser le clustering des données brutes sur le plan défini par les deux premiers axes d'une ACP non normée. Interpréter la partition en 5 classes obtenues sur les données brutes.Qu'en pensez-vous ?
3. Visualiser le clustering des données standardisées sur le plan défini par les deux premiers axes d'une ACP normée. Interpréter la partition en 5 classes obtenues sur les données standardisées.Qu'en pensez-vous ?
4. Suite aux résultats précédents, est il important de standardiser les données avant de faire un clustering ?

- **Données standardisées :** Variables centrées réduites
- **ACP normée :** c'est une ACP dont les variables sont centrées réduites

— **NB** :faites la CAH sur les données complètes avec toutes les variables puis représentez les groupes sur le plan défini par les deux premiers axes de l'ACP

Language utilisé : Python ou R