INSTITUT NATIONAL DES SCIENCES APPLIQUÉES ROUEN NORMANDIE

Département GM

RAPPORT PROJET MSRO

Classification Hiérarchique

Encadrant:
M. T. B. GNAMAH

Présenté par:
Mouad SHERADJ
DRISSI
Amr ZAKI SALIH

Année universitaire: 2024-2025

Table des matières

1 Introduction 2
2 Présentation du jeu de données 2
2.1 Statistique descriptive 2
3 Implémentation et interprétation des résultats obtenus 8
3.1 Clustering par CAH de Ward 8
3.2 Traitement avec données brutes 8
3.3 Traitement avec données standardisées 12
3.4 CAH consolidé 16
3.5 Comparaison des résultats obtenus avec les données brutes et standardisées 17
4 Conclusion 18

1 Introduction

Le but du projet est de réaliser un clustering sur des données standardisées et non standardisées pour pouvoir déterminer les principales différences entre ces deux classifications hiérarchiques. Pour cela on se propose de faire une analyse de données sur l'ensemble de données nommé "Obesity Classification", contentant des informations sur la classification de l'obésité des individus.

2 Présentation du jeu de données

"Obesity Classification" est un jeu de données contenant 4 variables quantitatives et 3 variables qualitatives qui sont respectivement :

- "Height", la taille des différents individus en centimètre
- "BMI", l'indice de masse corporelle ou IMC, calculé en divisant le poids par la taille au carré
- "Age", l'âge des différents individus
- "Weight", le poids des individus en kilogramme
- "ID" l'identifiant unique de chacun des individus
- "Sex" Le sexe de chacun des individu
- "Label", l'étiquette des individus qui peut être "Poids normal", "Surpoids", "Obésité", "Insuffisance pondérale"

Le jeu de données compte 108 observations correspondant aux 108 individus représentés. Lors de ce projet, nous nous concentrerons ainsi sur les données quantitatives car elles représentent directement la classification de l'obésité.

2.1 Statistique descriptive

On se propose dans un premier temps d'expliquer les données indépendamment pour pouvoir par la suite déterminer une classification hiérarchique compréhensible.

Analyse de la donnée "Height"

Nous allons ainsi visualiser rapidement la distribution de la variable "Height". Pour cela, nous allons réaliser dans un premier temps la boîte à moustache de la variable "Height".

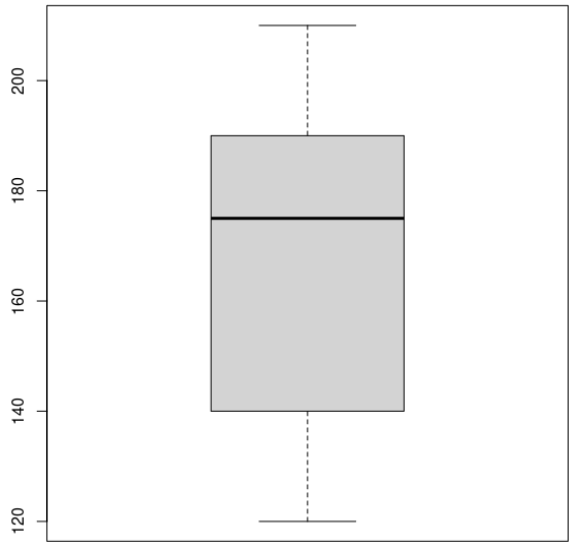


Figure 1.1 – *Boîte à moustache de la taille*

```
> summary(Taille)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  120.0   140.0   175.0   166.6   190.0   210.0
```

Figure 1.2 – *Résumé des données sur la taille*

On remarque ainsi dans un premier temps que les tailles vont de 120 centimètres(probablement enfant ou alors personnes très petites) jusqu'à 210 centimètres. La médiane est à 175 centimètres ce qui est cohérent avec une population majoritairement adulte et on a que la moyenne est légèrement inférieure à la médiane, on a ainsi une distribution légèrement asymétrique à gauche donc un peu plus de petites tailles que de grandes tailles.

Analyse de la donnée "Age"

Désormais, nous réalisons la boîte à moustache de la variable "Age", correspondant à l'âge des 108 individus.

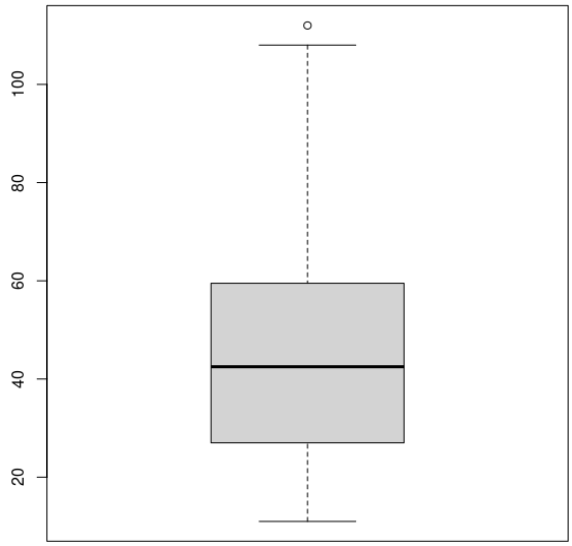


Figure 1.3 – *Boîte à moustache de l'âge*

```
> summary(age)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  11.00   27.00   42.50   46.56   59.25  112.00
```

Figure 1.4 – *Résumé des données sur l'âge*

La population est très hétérogène allant d'enfants de 11 ans à des personnes âgées de 112 ans. La médiane est à 42.5 ans indiquant que la moitié de l'échantillon a moins de cet âge. On remarque par ailleurs qu'il y a une distribution légèrement asymétrique à droite car la moyenne est supérieur à la médiane (présence de quelques personnes très âgées).

Analyse de la donnée "Weight"

Désormais, nous réalisons la boîte à moustache de la variable correspondant au poids.

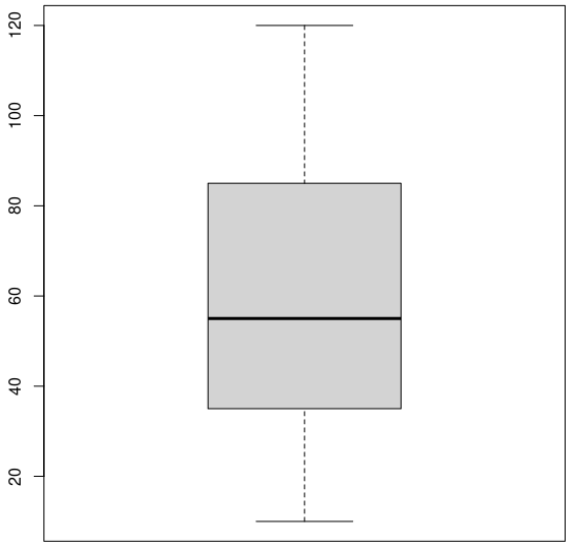


Figure 1.5 – *Boîte à moustache du poids*

```
> summary(Poids)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  10.00   35.00   55.00   59.49   85.00  120.00
```

Figure 1.6 – *Résumé des données sur le poids*

La population possède des poids très variées, allant de 10kg à 120 kg probablement dû à la présence d'enfants. La médiane est à 55 kg et la moyenne est à 59.5 kg, c'est-à-dire que la distribution est équilibrée mais qu'elle peut-être légèrement tirée vers le haut.

*Analyse de la donnée "BMI" Réalisons maintenant la boîte à moustache de la variable "BMI" correspondant à l'IMC.

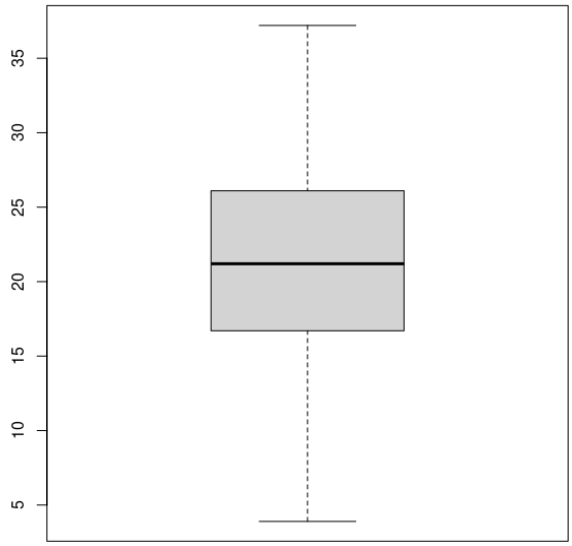


Figure 1.7 – *Boîte à moustache de l'IMC*

```
> summary(IMC)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   3.90   16.70   21.20   20.55   26.10   37.20
```

Figure 1.8 – *Résumé des données sur l'IMC*

D'après des données de bases, un IMC normal se présente généralement entre 18.5 et 24.9. On a un premier quartile à 16.7, cela veut dire que beaucoup de personnes sont sous la norme, donc probablement en sous-poids. La médiane est à 21.2 et la moyenne à 20.55 indiquant que la majorité est dans une zone saine.

Corrélation et régression linéaire

On décide de déterminer la corrélation entre les différentes variables pour déterminer à quel point les différentes variables sont corrélées.

```
Corrélation entre Age et Height : -0.077
Corrélation entre Age et Weight : 0.465
Corrélation entre Age et BMI : 0.474
Corrélation entre Height et Weight : 0.429
Corrélation entre Height et BMI : 0.354
Corrélation entre Weight et BMI : 0.973
```

Figure 1.9 – *Corrélation entre les variables*

On remarque ainsi que les deux variables les plus corrélées sont l'IMC et le poids ce qui paraît logique, puisque l'IMC est calculé en fonction du poids. Cependant, on aurait pu

imaginer que la taille ait une plus grande corrélation avec l'IMC, puisque l'on calcule l'IMC avec la taille aussi. Cela pourrait s'expliquer par le fait que la relation entre l'IMC et la taille est inversement proportionnelle au carré, puisque l'on calcule l'IMC de la sorte:

$$IMC = \frac{Poids}{Taille^2}$$

Réalisons ainsi la régression linéaire entre l'IMC et le poids :

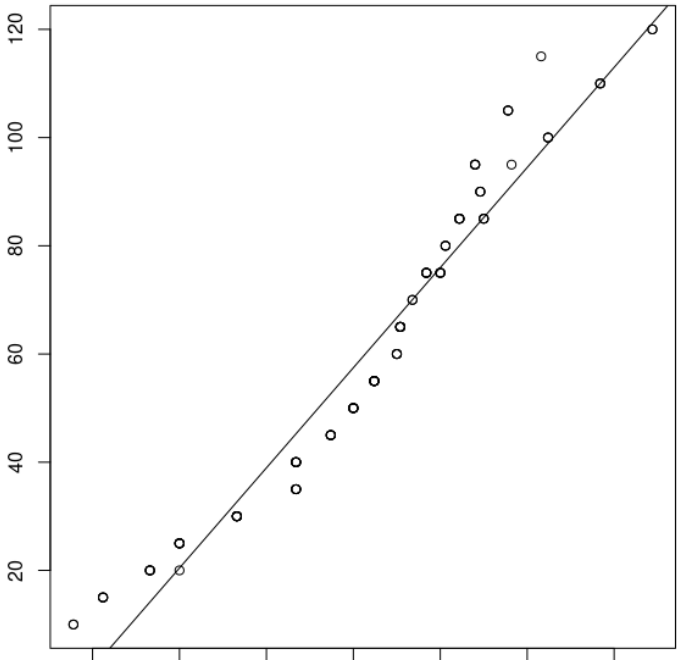


Figure 1.10 – *Régression linéaire*

```
                  Estimate Std. Error t value Pr(>|t|)
(Intercept)      -16.57352    1.87315  -8.848 2.18e-14 ***
Obesity_brute$BMI   3.70159    0.08556  43.261  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 6.712 on 106 degrees of freedom
Multiple R-squared:  0.9464,    Adjusted R-squared:  0.9459
F-statistic:  1871 on 1 and 106 DF,  p-value: < 2.2e-16
```

Figure 1.11 – *Résultats de la régression linéaire*

La régression linéaire du poids en fonction de l'IMC est extrêmement pertinente, le lien est très fort, significatif et presque tout le poids est expliqué par l'IMC. On peut ainsi utiliser ce modèle pour prédire la poids à partir de l'IMC avec une assez bonne précision. En effet, on a que le $R^2 = 0.9464$, ce qui signifie que ce modèle explique 94.6 pourcent de la variabilité du poids.

3 Implémentation et interprétation des résultats obtenus

Dans ce projet, nous avons réalisé une classification hiérarchique (CAH) sur des données relatives à l'obésité, en comparant les résultats obtenus sur des données brutes (non standardisées) et sur des données standardisées. L'objectif était d'évaluer l'impact de la standardisation sur la formation des clusters et leur interprétation à l'aide d'une Analyse en Composantes Principales (ACP).

3.1 Clustering par CAH de Ward

Le clustering de Ward est une méthode de classification hiérarchique qui vise à minimiser la variance intra-classes à chaque étape de la fusion. À chaque itération, les deux groupes dont la fusion entraîne la plus faible augmentation de la variance totale sont regroupés. Cette approche privilégie la compacité et l'homogénéité des clusters.

3.2 Traitement avec données brutes

Les données brutes, comprenant les variables Âge, Taille, Poids et IMC, n'ont pas été standardisées, ce qui signifie que les différences d'échelle entre ces variables (par exemple, Taille en centimètres et Âge en années) ont influencé directement le calcul des distances dans la CAH. Cela peut biaiser les résultats du clustering.

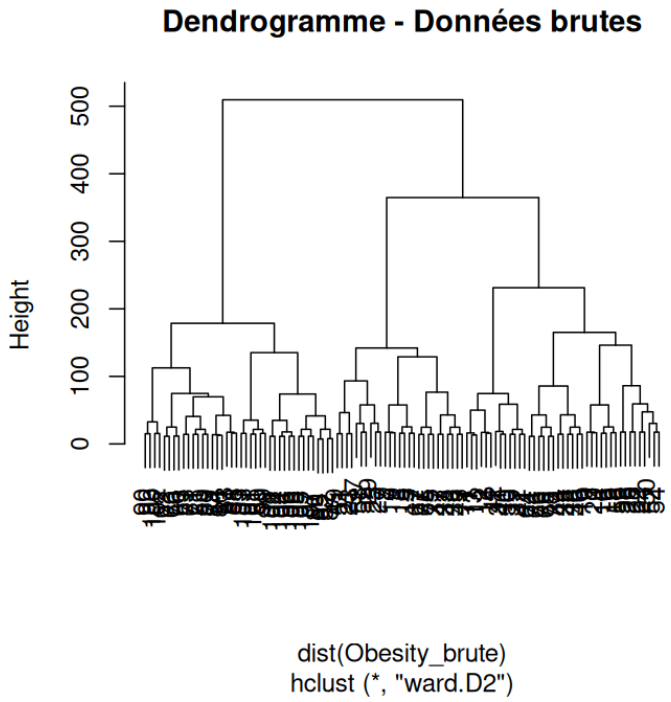


Figure 1.12 – *Dendrogramme de la CAH des données brutes, obtenu avec la méthode de Ward (ward.D2).*

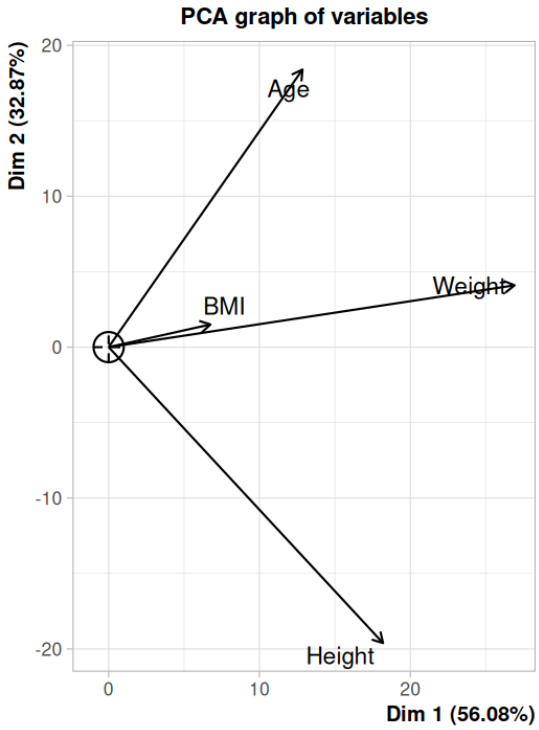


Figure 1.13 – *Cercle de corrélation de l'ACP non normée sur les données brutes.*

La figure 1.12 présente le dendrogramme de la CAH appliquée aux données brutes. Les fusions à des hauteurs élevées (supérieures à 400) suggèrent que les clusters finaux sont très éloignés, ce qui peut refléter une influence marquée des variables à forte variance, comme la taille et le poids.

La figure 1.13 montre l'ACP réalisée sans normalisation. Les deux premières dimensions expliquent respectivement $56,08\%$ (Dim 1) et $32,87\%$ (Dim 2) de la variance. La première dimension est principalement portée par le poids et l'IMC, tandis que la taille et l'âge y contribuent peu. La deuxième dimension est surtout influencée par l'âge, avec une contribution opposée de la taille. Les flèches dépassant le cercle de corrélation indiquent une forte contribution de ces variables.

Visualisation du clustering dans les axes de l'ACP

Dans cette section, nous avons fixé le nombre de clusters à 5 et visualisé les résultats du clustering hiérarchique (CAH) à l'aide d'une Analyse en Composantes Principales (ACP). Nous avons utilisé la méthode `HCPC` (Hierarchical Clustering on Principal Components) du package `FactoMineR` sous R avec l'option consol=FALSE qui n'active pas la consolidation, cette derniere combine une CAH (méthode de Ward) avec une ACP pour projeter les clusters dans un espace réduit. Cette approche nous a permis d'analyser la répartition des individus et la qualité des clusters à travers plusieurs visualisations, notamment des dendrogrammes et des projections sur les axes principaux.

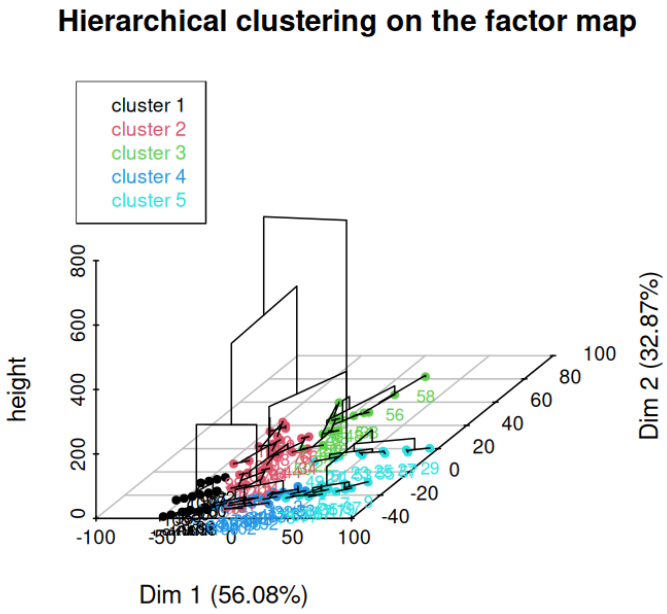


Figure 1.14 – *Projection 3D des individus sur les axes de l'ACP non normée avec clustering hiérarchique en 5 groupes. Les clusters sont distingués par des couleurs.*

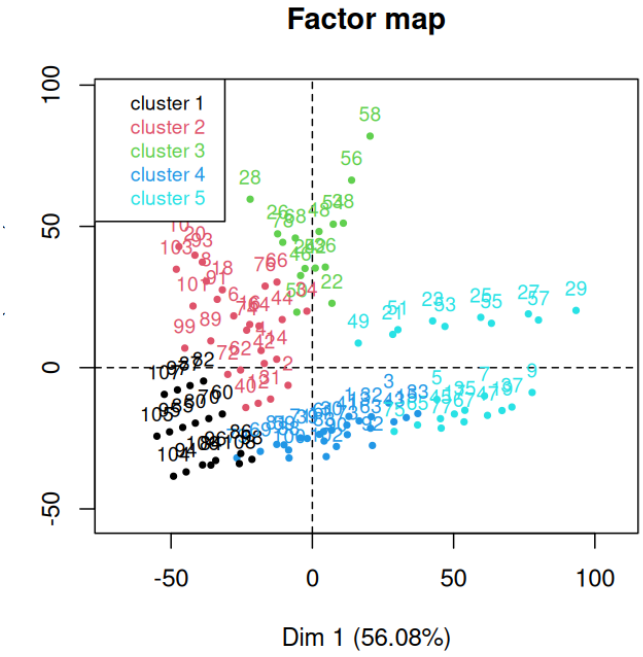


Figure 1.15 – *Projection des individus sur les deux premiers axes de l'ACP non normée.*

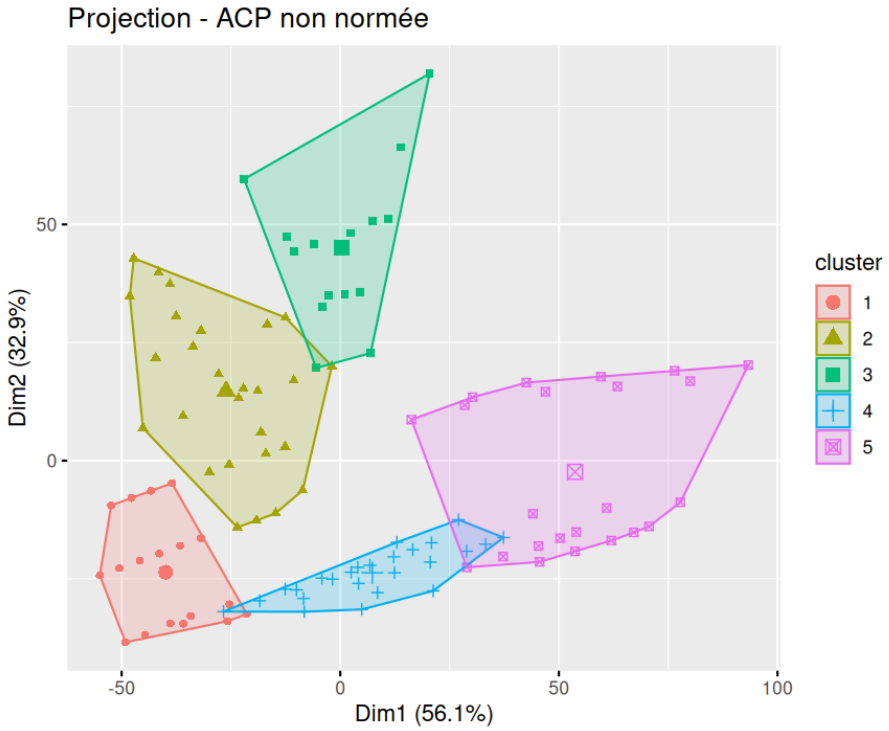


Figure 1.16 – *Projection des individus avec des formes, avec des contours délimitant chaque groupe.*

Les figures ci-dessous présentent les résultats du clustering hiérarchique appliqué aux données brutes. La figure 1.14 propose une visualisation en trois dimensions, mettant en évidence la séparation spatiale des clusters. La figure 1.15 montre la projection des individus sur les deux premiers axes de l'ACP, avec une distinction visuelle des groupes à l'aide de couleurs. Enfin, la figure 1.22, montre la projection des individus sur les deux premiers axes de l'ACP, avec une distinction visuelle des groupes à l'aide de couleurs, de formes et de contours. On observe un léger chevauchement entre certains clusters, ce qui suggère une séparation moins marquée, probablement liée à l'absence de standardisation des variables.

3.3 Traitement avec données standardisées

Standardisations des données

Application de la CAH

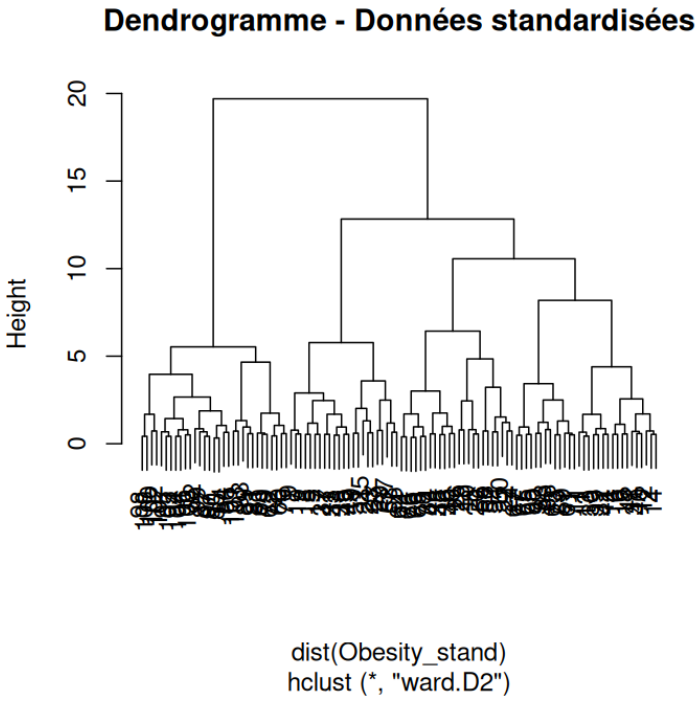


Figure 1.17

Le dendrogramme obtenu par classification ascendante hiérarchique (CAH) sur les données standardisées. Contrairement au données brutes où certaines fusions s'effectueraient à des hauteurs très élevées, ici, les regroupements se font de manière plus progressive, avec une hauteur maximale autour de 22. Cela suggère une structure de clusters relativement homogène et l'absence de groupes extrêmement distincts. D'ou on formation de cluster compact, minimisant l'inertie intra-classe.

Analyse en Composantes Principales

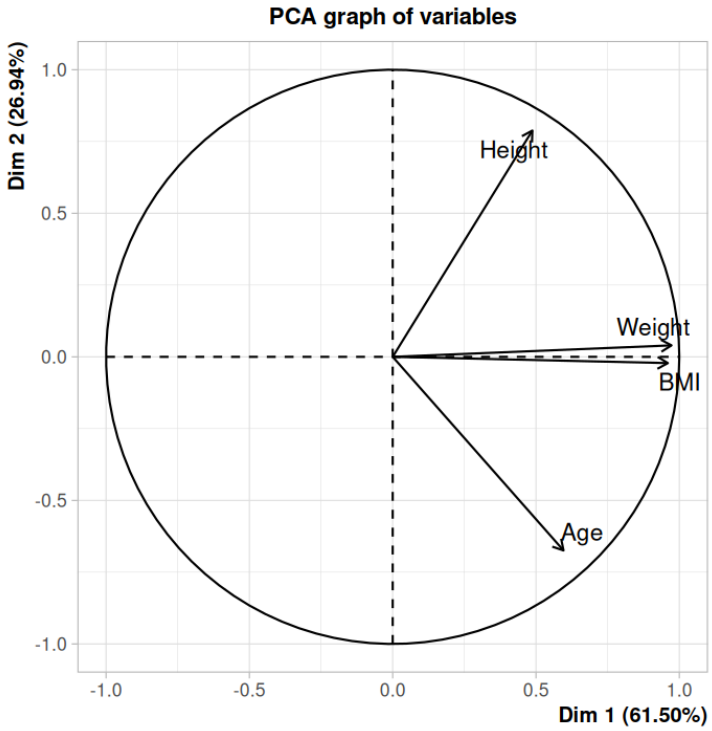


Figure 1.18

Le cercle des corrélations issu de l'analyse en composantes principales (ACP) sur les données normalisées, nous montre que les deux premières dimensions expliquent ensemble 88,44% de la variance totale, avec 61,50% pour la première composante (Dim 1) et 26,94% pour la seconde (Dim 2). La première dimension est fortement influencée par le poids et l'IMC, comme l'indiquent les flèches longues orientées vers la droite. La taille contribue surtout à la seconde dimension, tandis que l'âge présente une contribution importante en direction opposée sur cette même dimension. La longueur des flèches montre une bonne qualité de représentation des variables dans ce plan factoriel.

Visualisation du clustering dans les axes de l'ACP normées

Comme précédemment, nous avons fixé le nombre de clusters à 5 et visualisé les résultats de la CAH à l'aide d'une ACP. Nous avons utilisé la méthode `HCPC` avec l'option consol=FALSE qui n'active pas la consolidation, cette dernière combine une CAH (méthode de Ward) avec une ACP pour projeter les clusters dans un espace réduit mais cette fois-ci avec des données standardisées et normées.

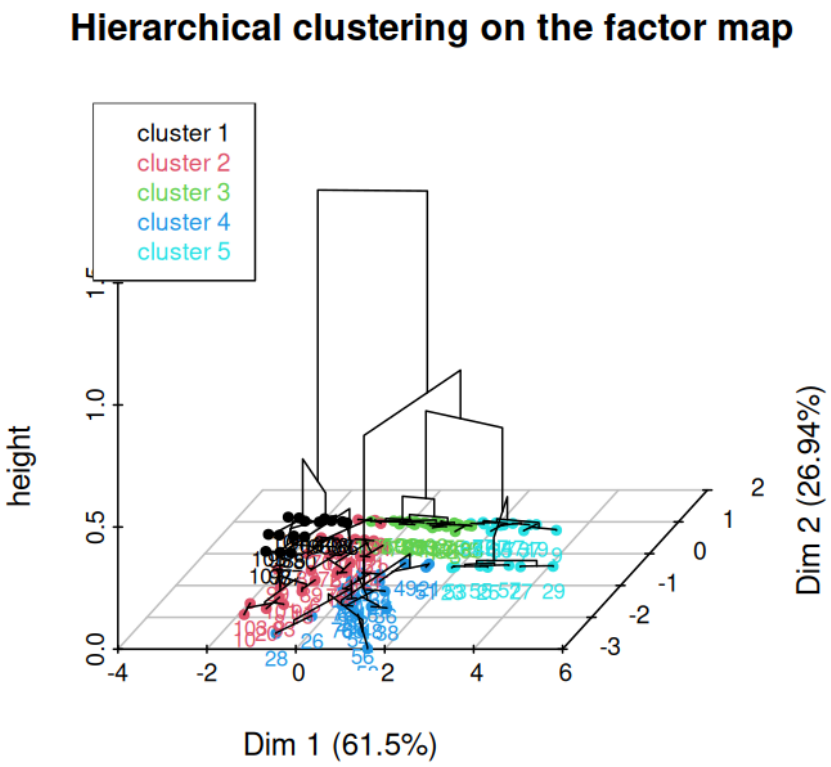


Figure 1.19 – *Projection 3D des individus sur les axes de l'ACP normés avec clustering hiérarchique en 5 groupes. Les clusters sont distingués par des couleurs.*

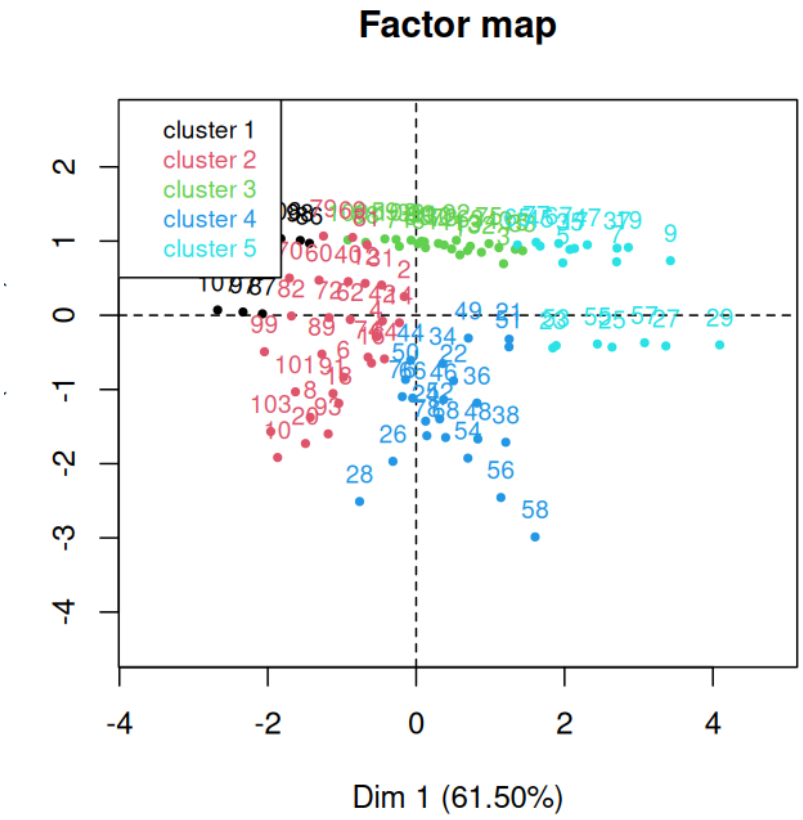


Figure 1.20 – *Projection des individus sur les deux premiers axes de l'ACP normés*

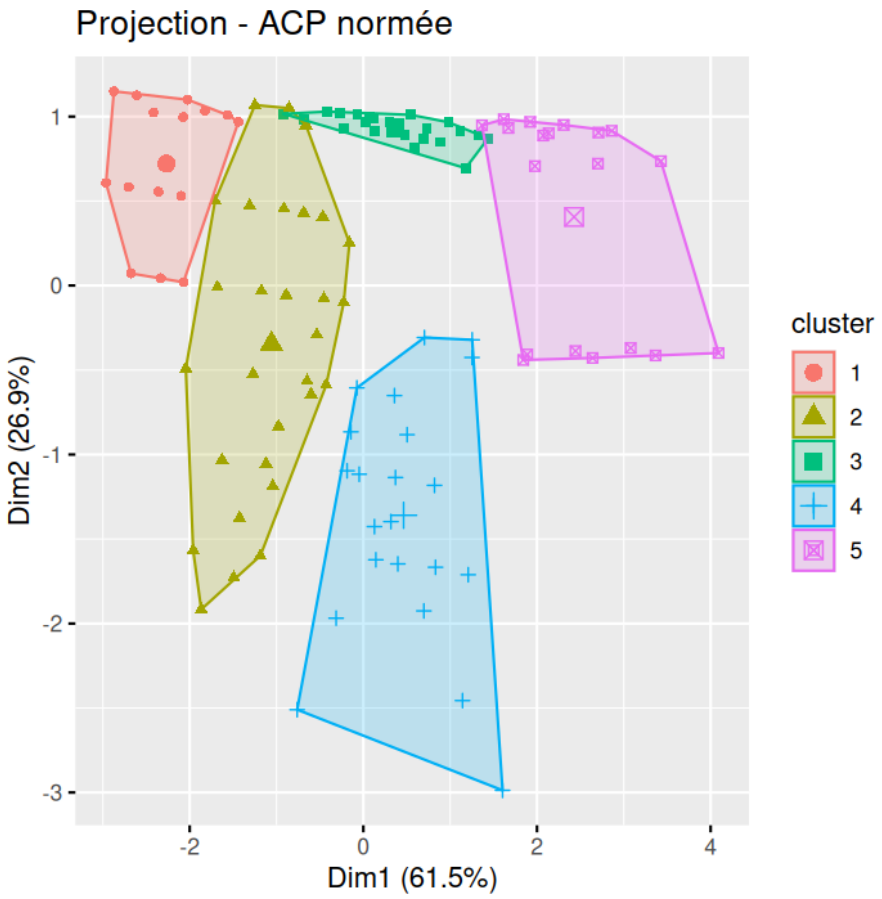


Figure 1.21 – *Projection des individus avec des formes, avec des contours délimitant chaque groupe*

Les figures illustrent les résultats du clustering hiérarchique sur les données standardisées. La figure 1.19 offre une visualisation 3D des mêmes données, mettant en évidence la séparation spatiale des clusters. La figure 1.20 montre une projection 2D (Dim 1 : 61.5%, Dim 2 : 26.94%) des individus sur les deux axes. Enfin, la figure 1.21, donne une distinctions entre les clusters qui sont distingués par des couleurs et des formes, avec des contours délimitant chaque groupe. On observe une séparation relativement nette entre les clusters, ce qui témoigne de l'efficacité de la standardisation dans la mise en évidence des structures sous-jacentes. Les regroupements sont bien distincts, en particulier pour les clusters 3, 4 et 5 qui sont spatialement bien séparés.

3.4 CAH consolidé

On rappelle dans un premier temps ce qu'est la CAH consolidé. Cette dernière est la combinaison entre les kmeans (la consolidation) et la CAH. Pour cela, il est nécessaire de réduire en dimension les données, c'est-à-dire réaliser une ACP.

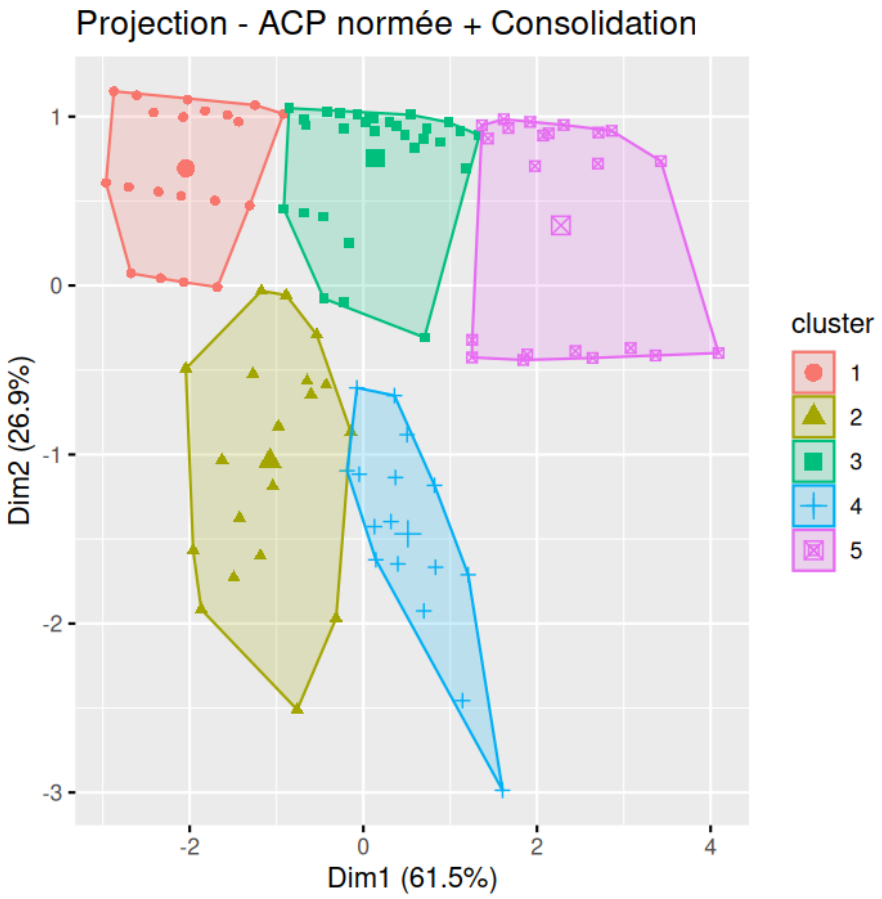


Figure 1.22

On remarque dès lors que le clustering de la méthode des CAH consolidés diffère par rapport à celui qui n'est pas consolidé. Dans le premier graphe (non consolidé), les clusters sont plus dispersés, avec le cluster 1 et le cluster 3 se chevauchant légèrement tandis que le cluster 4 lui est bien séparé. Il montre par ailleurs des clusters avec des formes irrégulières et une densité variable. Dans le deuxième clustering, les clusters sont plus compacts et mieux définis, avec une séparation plus nette entre les clusters 1,3 ainsi que 4. Il montre ainsi des clusters plus réguliers et consolidés suggérant une amélioration dans la cohérence interne des groupes. La consolidation semble avoir réduit le chevauchement, améliorant ainsi la distinction entre les clusters. On peut finalement dire qu'après consolidation, une séparation plus claire et des groupes plus cohérents sont offerts par la méthode par rapport au premier.

3.5 Comparaison des résultats obtenus avec les données brutes et standardisées

L'analyse comparative entre les données brutes et les données standardisées met en évidence l'importance de la phase de prétraitement dans une démarche de classification. Trois aspects principaux ressortent de cette comparaison : la structure des regroupements hiérarchiques, la lisibilité des clusters dans l'espace factoriel, et les indicateurs quantitatifs

d'inertie.

Structure des regroupements. Le dendrogramme issu des données brutes présente des fusions à des hauteurs très élevées (jusqu'à 500), traduisant des différences marquées entre certains groupes, potentiellement amplifiées par des variables à grande échelle comme la taille ou le poids. En revanche, le dendrogramme obtenu à partir des données standardisées montre une hiérarchie de regroupement plus progressive, avec une hauteur maximale d'environ 22. Cela suggère une structure plus homogène, où aucun groupe ne domine artificiellement en raison de son échelle. La standardisation permet ainsi d'atténuer l'effet de dominance des variables à forte variance et favorise des regroupements plus équilibrés.

Séparation visuelle des clusters. Les visualisations dans l'espace réduit de l'ACP révèlent une séparation plus nette et plus cohérente entre les groupes dans le cas des données standardisées. Sur les données brutes, plusieurs clusters présentent des chevauchements. En revanche, après standardisation, les clusters apparaissent bien délimités, avec une séparation particulièrement marquée entre les groupes 3, 4 et 5. Cela indique que la standardisation améliore la lisibilité des clusters et leur cohérence dans l'espace factoriel.

Analyse de l'inertie L'indicateur inertie inter-classe / intertie intra-classe mesure la qualité de la classification (plus il est élevée, meilleure est la séparation entre groupes) :

- Données brutes : **0,7337**
- Données standardisées (sans consolidation) : **0,7264**
- Données standardisées (avec consolidation) : **0,7457**

Malgré une légère baisse de l'inertie sans consolidation, les resultats reste un peu pres proche, la version consolidée des clusters sur données standardisées atteint le meilleur score, confirmant la robustesse des regroupements obtenus après standardisation. Cela souligne également l'intérêt de la consolidation (k-means appliqué après CAH) pour stabiliser les clusters initiaux.

4 Conclusion